Modelo Predictivo GermanCredit

Jaider Alberto Pardo Cárdenas
Universidad Nacional de Colombia

Introducción

En este trabajo desarrollaremos un modelo predictivo utilizando la base de datos GermanCredit para identificar los factores que influyen en el riesgo crediticio. Aplicaremos modelos estadísticos de tipo GLM con el objetivo de encontrar la herramienta más precisa para predecir si un préstamo es seguro o no. Para asegurar que elegimos la mejor opción, compararemos diferentes propuestas mediante una serie de pruebas estadísticas que nos permitirán evaluar su desempeño y confiabilidad de manera clara.

Explicación de la Base de Datos

La base de datos GermanCredit es un recurso estándar en el análisis estadístico que recopila información financiera de 1,000 solicitantes de crédito en Alemania. El objetivo de este conjunto de datos es distinguir entre clientes con buen y mal crédito basándose en diversas características personales y financieras. Para este modelo, trabajaremos con 10 variables fundamentales que describen la solvencia del cliente. Por un lado, evaluamos la magnitud del compromiso financiero mediante la Duración del crédito en meses y el Monto solicitado, factores que determinan la exposición al riesgo. También analizamos la estabilidad y el perfil del solicitante a través de su Edad, Duración de la Residencia, Número de Créditos vigentes y las Personas a Cargo. Finalmente, incluimos indicadores de capacidad de pago y contacto como el Porcentaje de la Cuota sobre el Ingreso, la posesión de Teléfono y si el solicitante es Trabajador Extranjero. Todas estas variables se utilizan para predecir la Clase, que etiqueta al cliente como 'good' (bajo riesgo) o 'bad' (alto riesgo).

1. Análisis descriptivo

Antes de proceder con la construcción del modelo estadístico, es fundamental realizar un análisis descriptivo para comprender cómo se distribuyen los datos y qué relación preliminar guardan con nuestra variable objetivo: **Clase**. Este análisis se divide en dos partes: el estudio de variables numéricas y el de variables categóricas.

1.1. Análisis de Variables Categóricas

En cuanto a las variables categóricas, nos enfocamos en: *Trabajador Extranjero*, *Teléfono*, *Duración de la Residencia* y *Porcentaje de Cuota sobre el Ingreso*. Para estas se generaron gráficos de barras apiladas mediante el siguiente código en R:

```
# Gráficos de barras apiladas al 100%
ggplot(df_clean, aes(x = PorcentajeCuotaIngreso, fill = Class)) +
  geom_bar(position = "fill")

ggplot(df_clean, aes(x = DuracionResidencia, fill = Class)) +
  geom_bar(position = "fill")

ggplot(df_clean, aes(x = Telefono, fill = Class)) +
  geom_bar(position = "fill")

ggplot(df_clean, aes(x = TrabajadorExtranjero, fill = Class)) +
  geom_bar(position = "fill")
```

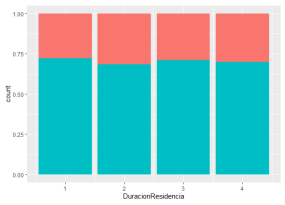

Figura 1: *
Cuota

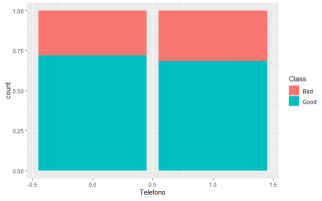

Figura 2: *
Residencia

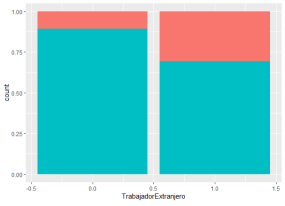

Figura 3: *
Teléfono

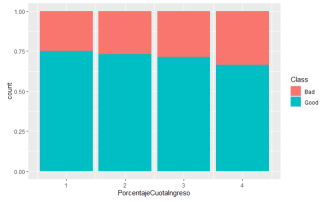

Figura 4: *
Extranjero

Figura 5: Distribución de la Clase según variables categóricas donde rojo es malo y azul es bueno.

Las visualizaciones obtenidas permiten observar si la proporción de buenos y malos clientes cambia según la categoría. Esto nos da indicios sobre qué variables apor-

tan mayor información para distinguir el riesgo crediticio. Al analizar los gráficos de barras apiladas, se identifican patrones clave que guiarán la selección de variables para el modelo. En primer lugar, se observa que a medida que aumenta el porcentaje de la cuota sobre el ingreso, se incrementa de manera evidente la proporción de créditos Bad, lo que confirma que una mayor carga financiera está asociada a un mayor riesgo crediticio.

Un hallazgo relevante se presenta en la variable Trabajador Extranjero, donde se evidencia que los solicitantes bajo esta condición presentan una concentración significativamente más alta de casos clasificados como 'Bad' en comparación con los nacionales. Esta marcada diferencia visual sugiere que dicha variable será fundamental en la explicación del modelo logístico. Por el contrario, factores como la Duración de la Residencia y la posesión de Teléfono muestran distribuciones muy similares entre ambas clases, lo que indica, de manera preliminar, que podrían no tener un impacto tan significativo en la probabilidad de incumplimiento.

1.2. Análisis de Variables Numéricas

Se realizó un estudio de las variables **Duración**, **Monto** y **Edad** mediante diagramas de caja, con el objetivo de identificar diferencias en las distribuciones según la clase del cliente. El código utilizado en R para generar estas visualizaciones fue:

```
# Generación de Boxplots comparativos
ggplot(df_clean, aes(x = Class, y = Duracion, fill = Class)) +
  geom_boxplot()

ggplot(df_clean, aes(x = Class, y = Monto, fill = Class)) +
  geom_boxplot()

ggplot(df_clean, aes(x = Class, y = Edad, fill = Class)) +
  geom_boxplot()
```

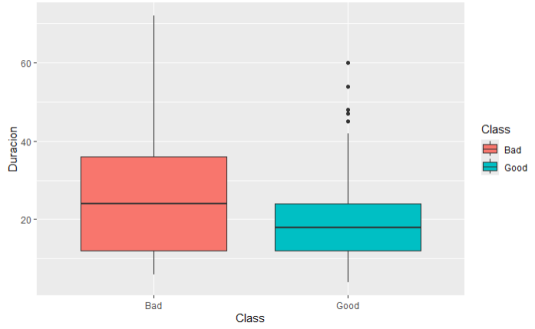

Figura 6: Distribución de la Duración del crédito.

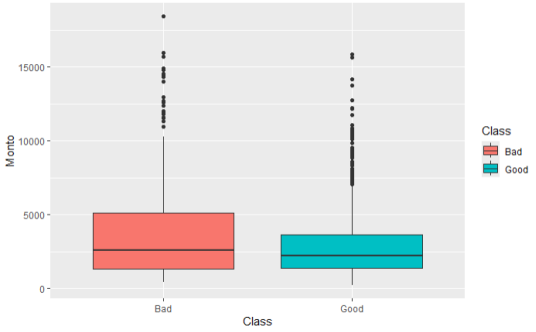

Figura 7: Distribución del Monto del crédito.

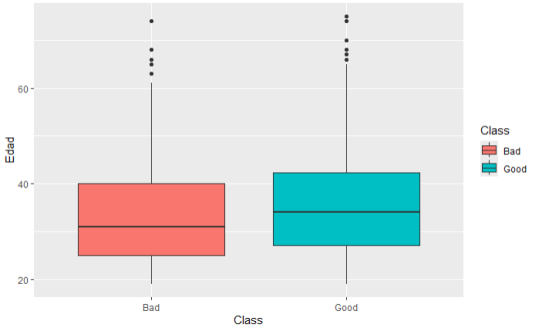

Figura 8: Distribución de la Edad de los clientes.

Al examinar detalladamente los diagramas de caja, se identifican comportamientos diferenciales según la calidad crediticia del solicitante. En la Figura 7 (Monto) y la gráfica de Duración, es evidente que el grupo 'Bad' presenta cajas desplazadas hacia valores más altos y una mayor cantidad de valores atípicos en la parte superior. Esto confirma que los créditos que implican montos significativamente elevados o plazos de pago inusualmente largos tienen una mayor probabilidad de ser clasificados como de alto riesgo.

Por otro lado, la Figura 8 (Edad) revela una distribución más compacta. Aunque la mediana de los buenos clientes es ligeramente superior, la amplia superposición de las cajas indica que la edad por sí sola no es un determinante absoluto, pero sí muestra que la estabilidad asociada a una mayor edad contribuye positivamente a la probabilidad de ser un cliente 'Good'. En conjunto, estas asimetrías en las distribuciones justifican la inclusión de estas tres variables en el modelo logístico, ya que su variabilidad ayuda al algoritmo a discriminar eficazmente entre ambos perfiles de riesgo.

La presencia de múltiples valores atípicos en el Monto y la Duración sugiere que el modelo logístico deberá lidiar con distribuciones sesgadas a la derecha, validando el uso de la función de enlace logit para manejar la naturaleza no lineal de estas relaciones.

Variable	**Correlación con *class_num***
Duración	-0.2149
Monto	-0.1547
Edad	0.0911
Número de Créditos	0.0457
Personas a Cargo	0.0030

Tabla 1: Correlación de Pearson entre variables numéricas y la variable objetivo.

La Tabla 1 permite profundizar en la naturaleza de los datos antes de proceder con el modelado, ofreciendo una visión clara sobre la fuerza de asociación entre los predictores numéricos y la probabilidad de éxito crediticio. Al observar los coeficientes, destaca de inmediato que la **Duración** y el **Monto** presentan las correlaciones negativas más pronunciadas. Dado que nuestra variable objetivo está codificada asignando el valor de 1 a los clientes solventes, este signo negativo confirma una premisa fundamental del riesgo: a medida que el compromiso financiero crece en cuantía y tiempo, la probabilidad de ser clasificado como un buen cliente disminuye sensiblemente.

Este análisis previo no solo ayuda a validar la direccionalidad del riesgo, sino que también funciona como un criterio de selección de variables. Por ejemplo, la correlación casi inexistente en factores como las **Personas a Cargo** sugiere que dicha variable carece de capacidad discriminante para separar los grupos de interés. Al integrar este hallazgo con la correlación de 0,62 detectada entre Monto y Duración, se hace evidente la necesidad de buscar un modelo final que sea parsimonioso y libre de redundancias.

2. Modelado de los Datos

En esta etapa del trabajo, comenzamos preparando nuestra información para que el modelo pueda procesarla correctamente. Lo primero que hicimos fue seleccionar únicamente las 10 variables de interés, dejando de lado el resto de la base de datos para simplificar el análisis.

Un paso fundamental fue ajustar nuestra variable objetivo, la **Clase**. Originalmente venía con etiquetas de texto, por lo que las convertimos en números: asignamos un **1** para los buenos clientes y un **0** para los malos. Además, ajustamos variables como el teléfono o si es trabajador extranjero para que el sistema las reconozca como categorías fijas. El proceso se realizó en R con el siguiente código:

```
df <- GermanCredit
df_clean <- df[, 1:10]

# Convertir Clase a numérica (1/0)
df_clean$Clase <- ifelse(df_clean$Class
                   == "Good", 1, 0)
df_clean$Clase <- as.factor(df_clean$Clase)

# Convertir variables a categorías
df_clean$PorcentajeCuotaIngreso <-
  as.factor(df_clean$InstallmentRatePercentage)
df_clean$DuracionResidencia <-
  as.factor(df_clean$ResidenceDuration)
df_clean$Telefono <-
  as.factor(df_clean$Telephone)
df_clean$TrabajadorExtranjero <-
  as.factor(df_clean$ForeignWorker)

# Renombrar para mayor claridad
names(df_clean)[1:10] <- c(
  "Duracion", "Monto", "CuotaIngreso",
  "Residencia", "Edad", "NumCreditos",
  "Cargas", "Tel", "Extranjero", "Class"
)
```

Una vez preparada la base de datos, procedimos a construir el modelo de predicción. Dado que nuestra variable objetivo (**Clase**) es dicotómica, la opción más adecuada es utilizar una distribución binomial con una función de enlace **logit**. Este enfoque permite calcular la probabilidad de que un cliente sea "bueno.º "malo"basándose en sus características personales.

Al ejecutar el modelo con todas las variables, obtuvimos los siguientes resultados en R:

```
# Modelo logístico full
modelo_full <- glm(Clase ~ Duracion + Monto +
               PorcentajeCuotaIngreso +
               DuracionResidencia + Edad +
               NumeroCreditos + PersonasACargo +
               Telefono + TrabajadorExtranjero,
               data = df_clean,
               family = binomial(link = "logit"))

Summary del modelo:
Coefficients:
                      Estimate  Std. Error z value Pr(>|z|)
(Intercept)            3.029e+00  7.075e-01   4.281 1.86e-05 ***
Duracion              -2.365e-02  7.778e-03  -3.041  0.00236 **
Monto                 -9.623e-05  3.542e-05  -2.716  0.00660 **
PorcentajeCuotaIngreso -2.143e-01  7.333e-02  -2.923  0.00347 **
DuracionResidencia    -4.261e-02  6.720e-02  -0.634  0.52609
Edad                   1.941e-02  7.091e-03   2.737  0.00620 **

NumeroCreditos         1.498e-01  1.314e-01   1.139  0.25453
PersonasACargo        -1.408e-01  2.025e-01  -0.695  0.48688
Telefono              -4.056e-01  1.578e-01  -2.571  0.01015 *
TrabajadorExtranjero  -1.078e+00  5.484e-01  -1.965  0.04938 * ---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

AIC: 1167.6
```

Como se observa, el modelo presenta variables que no son estadísticamente significativas (aquellas sin asteriscos y con p-valores altos). Por lo tanto, procederemos a realizar un proceso de selección de variables, eliminando las que no aportan valor para mejorar la precisión y confiabilidad de nuestra predicción final.

Tras observar que el primer modelo contenía variables que no aportaban significancia estadística, procedimos a realizar un proceso de eliminación hacia atrás (*backward elimination*). En el primer intento (`modelo_pre`), retiramos las variables con los p-valores más altos, pero la

variable **TrabajadorExtranjero** seguía mostrando una significancia marginal (marcada solo con un punto).

Por ello, generamos un último modelo (`modelo_m`) donde solo incluimos las variables que resultaron ser totalmente significativas. Los resultados de estas iteraciones se presentan a continuación:

```
# Modelo Intermedio (modelo_pre)
Coefficients:
                      Estimate  Pr(>|z|)
(Intercept)            2.965e+00  4.99e-06 ***
Duracion              -2.413e-02  0.00190 **
Monto                 -9.414e-05  0.00783 **
CuotaIngreso          -2.106e-01  0.00396 **
Edad                   1.866e-02  0.00600 **
Telefono              -4.090e-01  0.00928 **
TrabajadorExtranjero  -1.068e+00  0.05113 .
---
AIC: 1163.6

# Modelo Final (modelo_m)
Coefficients:
                      Estimate  Pr(>|z|)
(Intercept)            1.956e+00  2.36e-07 ***
Duracion              -2.597e-02  0.000792 ***
Monto                 -9.036e-05  0.010700 *
CuotaIngreso          -2.171e-01  0.002909 **
Edad                   1.865e-02  0.006118 **
Telefono              -3.828e-01  0.014688 * ---
AIC: 1166.4
```

Un paso crucial en este trabajo es evaluar cuál de las propuestas es la más óptima. Para esto, analizamos los indicadores de **AIC** (Criterio de Información de Akaike), **BIC** (Criterio de Información Bayesiano), la **Devianza** y la **Convergencia**. Estos valores nos permiten castigar la complejidad innecesaria y premiar la precisión.

A continuación, se presenta la tabla comparativa de los tres modelos desarrollados:

Modelo	AIC	BIC	Devianza	Conv.
Full	1167.61	1216.69	1147.61	TRUE
Pre	1163.63	1197.98	1149.63	TRUE
M	1166.44	1195.89	1154.44	TRUE

Tabla 2: Comparativa de indicadores de ajuste.

Al analizar la tabla, observamos que aunque el modelo `Full` tiene la menor devianza, el modelo **M** presenta el mejor balance de parsimonia (indicado por un BIC menor), asegurando que todas sus variables son significativas y que el algoritmo alcanzó la convergencia exitosamente.

3. Conclusión

Tras realizar una comparación exhaustiva entre las tres propuestas, se determina que el **Modelo M** es la mejor opción para predecir el riesgo crediticio en este estudio. Aunque el modelo inicial (*Full*) presentaba una devianza ligeramente menor, este comportamiento se atribuía únicamente a la inclusión de un mayor volumen de variables, muchas de las cuales no aportaban información estadísticamente significativa y terminaban generando ruido en la capacidad predictiva del sistema.

La elección del **Modelo M** se fundamenta sólidamente en el principio de parsimonia. Al observar que el valor del **BIC (1195.89)** es el más bajo de todos los modelos comparados, confirmamos que esta estructura es la que mejor equilibra el ajuste de los datos con la simplicidad del modelo. Resulta pertinente destacar que un modelo parsimonioso es especialmente valioso en este contexto debido a los niveles de correlación y colinealidad detectados en el análisis exploratorio; al eliminar variables redundantes o poco significativas, reducimos el riesgo de inflar las varianzas de los estimadores y aseguramos que factores como la duración, el monto y la edad sean verdaderos predictores del comportamiento del cliente. De esta manera, garantizamos un modelo robusto, eficiente y con una interpretación clara de los determinantes del riesgo crediticio.

```
modelo_m
Coefficients:
                      Estimate  Pr(>|z|)
(Intercept)            1.956e+00  2.36e-07 ***
Duracion              -2.597e-02  0.000792 ***
Monto                 -9.036e-05  0.010700 *
CuotaIngreso          -2.171e-01  0.002909 **
Edad                   1.865e-02  0.006118 **
Telefono              -3.828e-01  0.014688 * ---
AIC: 1166.4
```